

基于退火演化算法的知识获取机制的研究*

张雪江 朱向阳 钟秉林 黄 仁

(东南大学机械工程系·南京, 210096)

摘要: 针对专家系统知识获取的“瓶颈”问题, 本文从优化角度建立了一个最终可被归结为大规模组合优化问题的知识获取模型, 并通过基因遗传算法和模拟退火算法结合后所构成的退火演化算法求解该模型, 从而实现知识库的自动生成.

关键词: 知识获取; 组合优化; 退火演化算法;

1 知识获取模型的建立

知识获取是构造专家系统的主要“瓶颈”, 这一问题可通过机器学习加以解决. 目前较成功的学习方法主要有学习分类规则法 AQ_{11} 和基于信息熵及最大信息增益机制的决策树学习法 ID_3 ^[1]. 本文从优化角度提出一种新的学习方法, 并以机械设备故障诊断知识获取为例, 阐述该方法的可行性.

对于诊断型专家系统, 知识库的知识一般可用如下产生式规则表示:

$$R_i: \quad \text{IF } S_1 \& S_2 \& \dots \& S_n \quad \text{THEN } Q. \quad (1)$$

其中 S_i 是规则前提的属性, 取值为 1 或 0, 若为 1 表示该属性为真, 否则为非. Q 是规则结论, 对应于某一类别名称. 机器学习就是要从已有事例中获取上述规则, 这相当于为了获取关于类别 Q 的判别规则, 将该类事例作为学习训练的正面例, 而将其它事例(\bar{Q})作为学习训练的反面例, 通过适当的算法不断调整规则前提中各属性的取值, 最终找到一个尽最大可能覆盖正例而不覆盖反例的形如式(1)的描述, 以此作为关于类别 Q 的判别规则:

若在规则空间中, 存在一条关于类别 Q 的判别规则 R_i :

$$R_i: \text{IF } S_1^{<R_i>} \& S_2^{<R_i>} \& \dots \& S_n^{<R_i>} \quad \text{THEN } Q \quad (S_k^{<R_i>} \in \{0, 1\}, k=1, 2, \dots, n). \quad (2)$$

评价该规则的“优”与“差”需要考察如下两个方面: 一是它与关于类别 Q 的事例(正例)的吻合程度; 二是它与其它类别(\bar{Q})的事例(反例)的相离程度.

设关于类别 Q 共有 l 个正例, m 个反例, E_j 为其中的某一正例, 而 C_j 为其中的某一反例, 它们可用一个有序的 0, 1 二进制字符串来表示:

$$E_j: \text{IF } e_1^{<E_j>} \& e_2^{<E_j>} \& \dots \& e_n^{<E_j>} \quad \text{THEN } Q \quad (e_k^{<E_j>} \in \{0, 1\}, k=1, 2, \dots, n). \quad (3)$$

$$C_j: \text{IF } c_1^{<C_j>} \& c_2^{<C_j>} \& \dots \& c_n^{<C_j>} \quad \text{THEN } \bar{Q} \quad (c_k^{<C_j>} \in \{0, 1\}, k=1, 2, \dots, n). \quad (4)$$

规则 R_i 与正例 E_j 和反例 C_j 的相似程度可用如下的夹角余弦表示:

$$r < R_i, E_j > = \frac{\sum_{k=1}^n S_k^{<R_i>} e_k^{<E_j>}}{\sqrt{\sum_{k=1}^n (S_k^{<R_i>})^2} \cdot \sqrt{\sum_{k=1}^n (e_k^{<E_j>})^2}}, \quad (5)$$

* 国家自然科学基金(59275240)和江苏省应用基础基金资助项目(BJ95030).

本文于 1996 年 6 月 3 日收到, 1997 年 3 月 4 日收到修改稿.

$$r < R_i, C_j > = \frac{\sum_{k=1}^n S_k^{<R_i> C_j^{<C_j>}}}{\sqrt{\sum_{k=1}^n (S_k^{<R_i>})^2} \cdot \sqrt{\sum_{k=1}^n (C_k^{<C_j>})^2}}. \quad (6)$$

采用如下目标函数对规则 R_i 进行评价, F_{R_i} 越大, 表示规则 R_i 越适合于所给定的正反事例。

$$F(R_i) = \frac{1 + \sum_{j=1}^l r < R_i, E_j >}{1 + \sum_{j=1}^m r < R_i, C_j >}. \quad (7)$$

对于复杂的分类问题, 通常需要考虑几十个甚至数百个属性, 规则空间中的规则数由于组合爆炸而非常庞大。对于这类问题, 若采用函数 $F(R_i)$ 对规则进行评价, 则机器学习可归结为一个大规模组合优化问题。

2 知识获取模型的求解

对知识获取这一组合优化问题, 可以通过模拟退火算法或基因遗传算法求解, 但前者的搜索效率低, 而后者又难以保证解的质量。因此, 本文将提出一种新的求解方法——退火演化算法, 以较高的搜索效率来获取性能优良的分类规则。

2.1 模拟退火算法的求解过程及存在问题

模拟退火算法(Simulated Annealing, SA)的思想源于统计热物理学^[2]。该算法用于求解知识获取模型的基本思路为: 让温度类比参数 t_k 从一足够高的值下降, 在每一温度 t_k 下, 反复进行“产生新规则—判断—接受/舍弃”的(Metropolis)抽样, 即对当前规则 R_i 作一随机扰动产生新规则 R_j , 并按转移概率 P_i

$$P_i = \min \left[1, \exp \left[\frac{F(R_j) - F(R_i)}{t_k} \right] \right]. \quad (8)$$

确定是否接受新规则 R_j 。若上述 Metropolis 抽样过程的历经次数足够多, 则该温度下所产生的 Markov 链将渐近服从 Boltzman 分布。当温度 t_k 下降至满足给定的停步准则时, 终止算法。

在 Metropolis 抽样过程中, 以一定概率接受较差的规则, 使得 SA 算法在搜索过程中可以跳离局部最优解。但理论分析表明, SA 算法全局收敛的条件是: ①温度类比参数 t_k 必须按对数规律下降; ②每一温度下抽样次数足够多, 以满足抽样稳定性要求。因此, 从规则空间中搜索最优规则需要花费很长时间, 甚至由于难以承受的运行时间将使该算法丧失可行性。

2.2 基因遗传算法的求解过程及存在问题

基因遗传算法(Genetic Algorithm, GA)是模拟自然界生物进化机制的又一搜索寻优算法^[3]。将其用于求解知识获取模型时, 首先随机产生一系列规则, 作为进化的初始群体, 由式(7)评价各规则的适合度, 在按“优胜劣汰”的选择原则选种后进行繁殖、交叉、变异等操作, 这样经过若干代的演化后, 规则群体中最优规则的性能得到不断提高, 直至最后达到全局最优。

由于 GA 算法在规则空间的点群上而不是在一个单点上进行寻优, 因此, 提高了搜索速度。但在求解过程中, 必须选取适当的杂交率 p_c 和变异率 p_m 。杂交率过高会造成算法不稳定, 杂交率过低会引起未成熟收敛; 一定的变异率可以防止搜索过程被限制在解空间的某个仿射子空间上, 但变异率过高会使算法退化成随机搜索。

2.3 退火演化算法的求解策略

根据 SA 与 GA 的寻优特性, 将两者结合起来, 即将 GA 的群体演化机制引入到 SA 中, 构

成图 1 所示的退火演化算法 (Simulated Annealing-Genetic Algorithm, SAGA). 其基本思想: 从一个包含 N 条候选规则的初始群体出发, 在每一温度 t_k 下, 各候选规则都进行 L_k 次 Metropolis 抽样. 抽样后的群体包含了 $N(L_k + 1)$ 条候选规则, 对这些候选规则用式 (7) 评价后, 按自然选择原理从中选择 N 条规则形成基因池, 基因池中各基因经杂交、变异后形成新的后代, 然后降低温度 t_k , 重复以上过程, 重复次数 L 即为退火次数. 将 GA 引入到 SA 中后, 既有 GA 算法的多点搜索特性, 又有 SA 算法渐近收敛于全局最优解的特点, 从而提高了 SA 的搜索效率, 同时克服了 GA 算法由于杂交率、变异率的选取不当而搜索不到最优规则的问题, 保证了知识获取的稳健性.

```
Procedure SAGA
k := 0;
INITIALIZE ( $t_k, P(k)$ );
repeat
  for i := 1 to N do
    for j := 1 to  $L_k$  do
      GENERATE( $R_j$  from adjacent  $R_i$ );
      if  $\min\left[1, \exp\left[\frac{f(R_j) - f(R_i)}{t_k}\right]\right] > \text{random}[0,1]$ 
        then  $R_i = R_j$ ;
    EVALUATE  $P(k)$ ;
  k := k + 1;
  SELECT  $P(k)$  from  $P(k - 1)$ ;
  CROSSOVER and MUTATE;
   $t_k = \text{UPDATE}(t_{k-1})$ ;
until stop criterion
```

图 1 退火演化算法流程结构

3 知识获取示例

在大型旋转机械故障诊断中, 需要识别油膜振荡、质量不平衡、叶片结垢、转子碰摩、转子弯曲、转轴裂纹、转轴不对中及轴承座松动等故障, 现已获取了表 1 所示的典型故障事例:

表 1 故障事例

代号	故障类别	故障事例
Q ₁	油膜振荡	(1,4,5)(15,17)(4,5)(17,28,29)(4,5)(17,28),(5,17,24)(4,5,15)(4,17,24)
		(5,17,24)(4,5,15)(4,17,24)(5,17,24,29)(4,5,17)
Q ₂	质量不平衡	(2,6,11,18)(6,11,18)(11,14,18,25)(6,11,18)(2,11,14,18)(6,11,18)
		(6,11,14,18)(11,14,18)(3,11,18)(2,11,18,25)(2,11,18)(6,14,18,25)
Q ₃	叶片结垢	(11,18,25)(6,11,14,18)(6,11,18)
		(6,11,34,35)(6,15,19,34,37)(6,11,34,36,37)(6,11,35)(6,11,15,36)
Q ₄	转子碰摩	(15,19,35,36)(6,11,34,37)(6,11,15,35,36)
		(3,10,16,31,33)(10,16,20,22)(10,16,20)(3,10,31,33)(10,20,22)(10,16,20)
Q ₅	转子弯曲	(10,16,20,22)(10,15,20)(10,20,22)
		(12,15,23,32)(12,19,23,32)(6,12,23,32)(3,15,19,25)(6,15,23)(12,19,23)
Q ₆	转轴裂纹	(19,25,32)(3,12,23)(3,6,15,19)(6,12,19,25)(12,18,23)(15,19,32)
		(3,15,19,25)(13,23,32)
Q ₇	转轴不对中	(8,13,23,27)(3,13,23,26)(13,26,27)(3,8,23,27)(8,15,23)(8,13,26,27)
		(13,23,26)(15,23,27)(8,13,27)(15,26,27)
Q ₈	轴承座松动	(13,23,25)(7,13,23)(7,13,23,25)(7,13,23)(3,7,15,23)(8,23,25)
		(3,13,23,25)(3,7,13,23)(7,13,23)(15,23,25)(7,13,23)(13,23,25)

注: 右栏故障事例中, 一对括号对应一事例, 括号中的编号对应于表 2 中的症状属性.

对表 1 所列的每一类故障, 分别用 SA, GA 和 SAGA 三种方法来搜索最优规则, 将搜索结果即目标函数值列于表 3~表 5 中. 为比较搜索效率及鲁棒性, 各方法都选用了一系列不同的

控制制参数 (L_k : Metropolis 抽样次数; L : 退火次数或进化次数; p_c : 杂交率; p_m : 变异率)。

表 2 故障事例的症状属性

1 振动波形发生畸变出现截波现象	2 轴心轨迹呈椭圆
3 轴心轨迹呈香蕉形或长条形	4 轴心轨迹呈 8 字形
5 频谱中 0.3~0.5 倍频低频分量较突出	6 频谱中有明显的基频分量
7 频谱中有明显的二倍频分量	8 频谱中有明显的三倍频分量
9 频谱中出现了高次奇数倍频	10 频谱中出现了从低频到高频的广频成分
11 频谱中基本上无 2X 和 3X 分量	12 除主要的工频分量还有 2X 和 3X 分量
13 除主要的 2X 分量外,还有一定的 1X 和 3X 分量	14 振幅变化不大
15 振幅增大	16 振幅增大且忽大忽小地变化
17 低频分量增大	18 工频分量变化不大
19 工频分量增大	20 工频分量增大且忽大忽小地变化
21 倍频分量变化不大	22 倍频分量增大且忽大忽小地变化
23 倍频分量增大	24 升降速时,低频成分基本不变
25 升降速时,振幅及工频分量呈抛物线变化	26 过临界转速时,1X 和 2X 分量不稳定
27 过 1/2 及 1/3 临界转速时,振幅相位有明显的变化	28 轴承内有金属撞击声
29 转子外露部分有颤动现象	30 转子轴向位移增大
31 转子差胀增长	32 转子偏心增大
33 机体上下缸的温差增大	34 凝结水硬度大于 5 微克当量每升
35 凝结水含氧量大于 50 微克每升	36 凝结水 pH<7
37 凝结水导电度大于 1 微欧每厘米	38 轴承四周振动及基础附近振动差异增大
39 垂直振动与水平振动幅值差异增大	40 垂直振动与水平振动高频分量差异增大

表 3 SA 的搜索结果

试验参数		Q_1	Q_2	Q_3	Q_4	Q_5	Q_6	Q_7	Q_8
$L = 450$	$L_k = 50$	8.54	3.40	2.25	2.11	1.91	3.51	2.30	2.42
	$L_k = 100$	10.67	10.14	6.86	6.25	9.90	4.39	4.840	7.35
	$L_k = 150$	11.96	12.75	6.91	7.32	10.47	9.16	10.10	7.35
	$L_k = 200$	11.96	12.75	6.91	7.32	10.47	9.16	10.10	7.35
$L_k = 150$	$L = 100$	10.67	2.41	1.88	1.93	3.92	2.78	2.460	1.77
	$L = 200$	11.96	9.06	6.31	2.16	7.59	7.06	8.36	6.66
	$L = 300$	11.96	12.53	6.86	5.14	10.47	9.16	10.10	7.35
	$L = 400$	11.96	12.75	6.91	7.32	10.47	9.16	10.10	7.35
	$L = 500$	11.96	12.75	6.91	7.32	10.47	9.16	10.10	7.35

表 3~表 5 表明:用 SA 搜索最优规则,只有在退火次数 L 及各温度下的 Metropolis 抽样次数 L_k 取值足够大时($L \geq 450, L_k \geq 150$),才能搜索到最优规则,但此时需要花费很长的搜索时间.用 GA 算法只需经历 30 次进化,算法就能收敛,收敛速度快,搜索时间短.但当杂交率和变异率取不同值时,所得诊断规则的性能差异很大,GA 对知识获取的稳健性较差.而 SAGA 算法不仅大大提高了 SA 算法的搜索速度(由 $L = 450, L_k = 150$,变为 $L = 40, L_k = 50$),而且杂交率和变异率这两个控制参数选用不同的值不影响最终所得规则的性能,对知识获取具有很强的鲁棒性.

将 SAGA 算法所搜索到的最优诊断规则列于表 6 中,对照表 6 和表 1,可以看出每类故障

的判别规则均能较好地反映其事例.

表 4 GA 的搜索结果

试验参数		Q_1	Q_2	Q_3	Q_4	Q_5	Q_6	Q_7	Q_8
$L = 30$ $p_m = 0.015$	$p_c = 0.5$	8.64	10.04	6.84	5.83	9.09	9.16	7.56	5.81
	$p_c = 0.6$	10.46	11.10	6.48	4.24	10.47	7.96	10.10	6.48
	$p_c = 0.7$	11.96	10.69	6.31	6.15	9.90	7.96	10.10	7.35
	$p_c = 0.8$	11.96	9.01	4.99	7.32	8.54	7.58	6.51	5.81
	$p_c = 0.9$	11.96	10.42	5.32	7.32	9.21	5.85	10.10	6.48
$L = 30$ $p_c = 0.85$	$p_m = 0.005$	7.95	7.28	4.51	5.28	8.80	6.38	10.10	5.68
	$p_m = 0.015$	11.96	11.76	5.72	6.70	9.90	9.16	8.63	5.81
	$p_m = 0.025$	8.45	10.41	6.91	7.32	9.51	7.58	10.10	7.35
	$p_m = 0.035$	7.43	12.53	4.94	4.35	6.79	5.94	6.54	5.81
	$p_m = 0.045$	5.86	6.81	4.29	3.94	4.92	4.78	5.85	4.62

表 5 SAGA 的搜索结果

试验参数		Q_1	Q_2	Q_3	Q_4	Q_5	Q_6	Q_7	Q_8
$L = 40$ $L_k = 50$ $p_m = 0.015$	$p_c = 0.5$	11.96	12.75	6.91	7.32	10.47	9.16	10.10	7.35
	$p_c = 0.6$	11.96	12.75	6.91	7.32	10.47	9.16	10.10	7.35
	$p_c = 0.7$	11.96	12.75	6.91	7.32	10.47	9.16	10.10	7.35
	$p_c = 0.8$	11.96	12.75	6.91	7.32	10.47	9.16	10.10	7.35
	$p_c = 0.9$	11.96	12.75	6.91	7.32	10.47	9.16	10.10	7.35
$L = 40$ $L_k = 50$ $p_c = 0.85$	$p_m = 0.005$	11.96	12.75	6.91	7.32	10.47	9.16	10.10	7.35
	$p_m = 0.015$	11.96	12.75	6.91	7.32	10.47	9.16	10.10	7.35
	$p_m = 0.025$	11.96	12.75	6.91	7.32	10.47	9.16	10.10	7.35
	$p_m = 0.035$	11.96	12.75	6.91	7.32	10.47	9.16	10.10	7.35
	$p_m = 0.045$	11.96	12.75	6.91	7.32	10.47	9.16	10.10	7.35

表 6 应用 SAGA 获取的诊断规则

Q_1 :	如果	轴心轨迹呈 8 字形 & 频谱中 0.3 ~ 0.5 倍频低频分量较突出 & 低频分量增大
	则	油膜振荡
Q_2 :	如果	频谱中有明显的基频分量 & 频谱中基本上无 2X 和 3X 分量 & 工频分量变化不大
	则	质量不平衡
Q_3 :	如果	频谱中有明显的基频分量 & 频谱中基本上无 2X 和 3X 分量 &
		凝结水硬度大于 5 微克当量每升 & 凝结水导电度大于 1 微欧每厘米
	则	叶片结垢
Q_4 :	如果	频谱中出现了从低频到高频的广频成分 & 振幅增大且忽大忽小地变化 &
		工频分量增大且忽大忽小地变化
	则	转子碰摩
Q_5 :	如果	除主要的工频分量还有 2X 和 3X 分量 & 工频分量增大 & 倍频分量增大 & 转子偏心增大

续表 6 应用 SAGA 获取的诊断规则

	则	转子弯曲
Q ₆ :	如果	频谱中有明显的三倍频分量 & 除主要的 2X 分量外,还有一定的 1X 和 3X 分量 & 倍频分量增大 & 过临界转速时,1X 和 2X 分量不稳定 & , 过 1/2 及 1/3 临界转速时,振幅相位有明显的变化
	则	转轴裂纹
Q ₇ :	如果	频谱中有明显的二倍频分量 & 除主要的 2X 分量外,还有一定的 1X 和 3X 分量 & 倍频分量增大
	则	转轴不对中
Q ₈ :	如果	频谱中出现了从低频到高频的广频成分 & 振幅增大且忽大忽小地变化 & 工频分量增大且忽大忽小地变化 & 轴承四周振动及基础附近振动差异增大
	则	轴承座松动

4 结 论

从事例中获取知识可以归结为一个大规模组合优化问题,对该优化问题可以通过模拟退火算法或基因遗传算法求解.模拟退火算法能够保证搜索到全局最优的规则,但搜索速度慢,搜索时间长.基因遗传算法采取群体搜索,搜索速度快,但若杂交率和变异率这两个控制参数选取不当,将难以搜索到最优规则.本文将 GA 算法和 SA 算法相结合,提出的退火演化算法无论在搜索速度还是在最终解的质量及知识获取的鲁棒性上都得到了极大的改善.从应用示例看,这种知识获取机制只需预先确定一个优化目标函数,通过寻优手段即能从已有事例中获取最优分类规则,实现知识库的自动生成,它为解决诊断型专家系统知识获取的“瓶颈”问题提供了一条有效途径.

参 考 文 献

1 Liu and White,A. P. . A review of inductive learning. Proc of ES'91,London,1991,112—126
2 Kirkpatrick,S. . Optimization by Simulated annealing. Science,1983,220(5):671—679
3 David,B. and Fogel. An introduction to simulatied evolutionary optimization. IEEE Trans. Neural Networks,1994,5(1):3—14

Research on Annealing-Genetic Algorithm Based Knowledge Acquisition

ZHANG Xuejiang, ZHU Xiangyang, ZHONG Binglin and HUANG Ren
(Department of Mechanical Engineering,Southeast University • Nanjing,210018,PRC)

Abstract: Knowledge acquisition is a “bottleneck” for building expert system. In this paper,a realvalued criterion is proposed to evaluate the performance of the rule. On this basis,knowledge acquisition is reduced to a large-scale combinatorial optimization problem. A hybrid approach with the genetic algorithm being embedded in simulated annealing,which is defined as annealing-genetic algorithm,is proposed to solve the problem. By this strategy,the knowledge base can be automatically generated from examples.
Key words: knowledge acquisition; combinatorial optimization; annealing-genetic algorithm

本文作者简介

张雪江 1964 年生. 1986 年毕业于东北重型机械学院, 1989 年、1997 年于东南大学分别获得硕士、博士学位. 现在南京中兴新通讯设备研究所, 从事通讯产品的开发工作. 研究方向为计算机通信, 人工智能, 专家系统及智能故障诊断, 发表学术论文 10 余篇.

朱向阳 1966 年生. 1985 年毕业于南京工学院自动控制系, 1989 年、1992 年于东南大学分别获得硕士、博士学位, 1993 年至 1995 年在华中理工大学从事博士后研究. 现为东南大学机械系副教授, 研究方向: 机器人学, 智能故障诊断, 非线性分析, 最优化方法及应用, 信息处理. 曾获部级科技进步二等奖 1 项, 发表学术论文 20 余篇.

钟秉林 1951 年生. 1977 年毕业于南京工学院机械系, 1994 年于英国 Wales 大学获博士学位. 现为国家教委高教司司长, 东南大学博士生导师. 研究方向: 智能故障诊断, 系统辨识, 信息处理. 曾获省部级科技成果奖 3 项, 发表学术论文 40 余篇.

黄 仁 1928 年生. 1952 年毕业于同济大学机械系, 1981 年至 1982 年在美国 Wisconsin-madison 大学高访, 现为东南大学机械系教授. 研究方向为智能故障诊断, 时间序列分析. 曾获省部级科技成果奖 4 项, 发表学术论文 70 余篇.

中国科技期刊排行表

(按被引频次和影响因子排序)

数学类:

名次	期 刊 名 称	被引频次	名次	期 刊 名 称	影响因子
1	数学学报	306	1	控制理论与应用	0.2348
2	应用数学和力学	184	2	计算数学	0.2184
3	应用数学学报	157	3	数值计算与计算机应用	0.1818
4	计算数学	148	4	应用概率统计	0.1724
5	数学年刊. A	134	5	数学学报	0.1591
6	系统科学与数学	117	6	系统科学与数学	0.1579
7	控制与决策	108	7	系统工程学报	0.1573
8	系统工程理论与实践	104	8	应用数学学报	0.1486
9	数学研究与评论	86	9	高等学校计算数学学报	0.1413
10	应用概率统计	85	10	J Comput Math	0.1389

说明:

1. 中国科学引文数据库在连续两年公布《被引频次最高的中国科技期刊 100 名排行表》的基础上, 为使统计数据的排列从多种角度反映科技期刊状况, 特从 1996 年开始按学科编制《中国科技期刊排行表(按被引频次和影响因子排序)》.
2. 被引频次是在对被中国科学引文数据库 1996 年 582 种来源期刊所引用的数千种中国出版的中英文期刊进行频次统计后编制而成.
3. 影响因子的计算方法如下:
- 1996 年某刊的影响因子 = $\frac{1996 \text{ 年引用 } 1994 \text{ 年和 } 1995 \text{ 年该刊刊载论文的总次数}}{1994 \text{ 年和 } 1995 \text{ 年该刊刊载论文的总次数}}$
- 本表中 1996 年的影响因子是在对中国科学引文数据库 1994 年—1995 年的来源期刊作了统计后编制而成. 由于计算影响因子受到期刊发文量数据的限制, 因此, 本表中只对能在中国科学引文数据库获得发文量数据的 315 种期刊作了统计. 1996 年新增加的 267 种来源期刊因无发文量数据而未作统计.
4. 本着尊重原始数据的原则, 本表对变名期刊未作任何合并处理.

①数据来源: 中国科学院文献情报中心中国科学引文数据库 1996 年数据.
本表由中国科学引文数据库统计编制.